

Trường Đại học Khoa học Tự nhiên, ĐHQG-HCM

Khoa Công nghệ Thông tin

Môn học: Toán Ứng Dụng và Thống Kê (MTH00051)

ĐỒ ÁN 2

Data Fitting và Phương Pháp OLS

Giảng viên hướng dẫn:

ThS. Võ Nam Thực Doan

ThS. Lê Nhật Nam

Nhóm thực hiện: Nhóm 14

Ngày 30 tháng 5 năm 2026

Mục lục

Phân Công Công Việc	2
1 Phần 1: Lý Thuyết Data Fitting và Minh Họa	3
1.1 Bài Toán Data Fitting và Giả Thiết Gauss-Markov	3
1.1.1 Phát biểu bài toán tổng quát	3
1.1.2 Các Giả Thiết Gauss-Markov	3
1.2 Ordinary Least Squares (OLS)	3
1.3 Hat Matrix	4
1.4 Đánh Giá Mô Hình & Suy luận thống kê	4
1.5 Đa Cộng Tuyến và Hệ Số Phóng Đại Phương Sai (VIF)	5
1.6 Ridge Regression và K-Fold Cross Validation	6
1.7 Phân Tích Phần Dư (Residual Analysis)	7
1.8 Minh Họa Định Lý Gauss-Markov	8
2 Phần 2: Ứng Dụng Dữ Liệu Thực Tế	10
2.1 Giới Thiệu và Khám Phá Dữ Liệu (EDA)	10
2.2 Xây Dựng và Đánh Giá Mô Hình	12
2.3 Chẩn đoán giả thiết phần dư Gauss-Markov trên dữ liệu thực	13
2.4 Giải thích Mô hình (Feature Importance)	15
2.5 Kỹ Thuật Nâng Cao: Hồi Quy Tuyến Tính Bayes (Bayesian Linear Regression) .	15
3 Kết Luận	16

Phân Công Công Việc

Dưới đây là bảng phân công công việc chi tiết của 5 thành viên trong nhóm, tuân thủ nguyên tắc phát triển phần mềm độc lập giữa tầng logic (Code) và tầng trình bày (Notebook):

STT	Họ và tên	MSSV	Nhiệm vụ	Hoàn thành
1	Nguyễn Lê Anh Tuấn	24120153	Code Part 1: Cài đặt thuật toán từ đầu (from scratch) bằng NumPy: OLS, Ridge, K-Fold CV, VIF và biểu đồ phần dư (<code>part1/*.py</code>).	100%
2	Trần Trung Kiên	24120079	Notebook 1: Trình bày lý thuyết Toán, gọi hàm minh họa tập giả lập, so sánh với sklearn, mô phỏng Monte Carlo (<code>part1_notebook.ipynb</code>).	100%
3	Huỳnh Thành Phát	24120212	Code Part 2: Xây dựng OOP DataPipeline (tránh rò rỉ dữ liệu), KN-Imputer, Winsorization và cài đặt Bayesian Regression (<code>part2/*.py</code>).	100%
4	Đỗ Bá Lâm	24120082	Notebook 2: Chạy EDA dữ liệu AirQualityUCI, đánh giá MAE/RMSE/ R^2 3 mô hình, phân tích Feature Importance (<code>part2_notebook.ipynb</code>).	100%
5	Trần Đại Hiệp (PM)	23120256	Quản lý tiến độ chung. Kiểm duyệt chất lượng mã nguồn (QA). Trực tiếp soạn thảo, format báo cáo bằng LaTeX và đóng gói thư mục nộp bài.	100%

Bảng 1: Bảng phân công công việc và đánh giá mức độ hoàn thành của nhóm.

1 Phần 1: Lý Thuyết Data Fitting và Minh Họa

Data Fitting (hay Khớp Dữ Liệu) là bài toán tìm kiếm một hàm toán học phù hợp nhất để mô tả mối quan hệ giữa các biến đầu vào và biến mục tiêu. Mục tiêu của quá trình này là xây dựng một mô hình có khả năng xấp xỉ quy luật của dữ liệu thực nghiệm, từ đó phục vụ cho việc dự đoán, phân tích và tối ưu hóa trong nhiều lĩnh vực như khoa học dữ liệu, kỹ thuật và Machine Learning.

Trong phần này, nhóm tiến hành cài đặt hoàn toàn từ đầu (from scratch) các thuật toán cốt lõi bằng ma trận thông qua thư viện `numpy`, đồng thời kiểm chứng kết quả trên bộ dữ liệu mô phỏng theo chuẩn phân phối Gauss-Markov.

1.1 Bài Toán Data Fitting và Giả Thiết Gauss-Markov

1.1.1 Phát biểu bài toán tổng quát

Cho tập dữ liệu $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^n$ với $x_i \in \mathbb{R}^p$ và $y_i \in \mathbb{R}$. Bài toán hồi quy tuyến tính giả thiết mối quan hệ có dạng:

$$y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_p x_{ip} + \epsilon_i = x_i^T \beta + \epsilon_i \quad (1)$$

Viết dưới dạng ma trận tổng quát:

$$y = X\beta + \epsilon \quad (2)$$

Trong đó, $y \in \mathbb{R}^n$ là vector mục tiêu, $\beta = (\beta_0, \beta_1, \dots, \beta_p)^T \in \mathbb{R}^{p+1}$ là vector hệ số cần ước lượng, $\epsilon \in \mathbb{R}^n$ là vector nhiễu ngẫu nhiên, và $X \in \mathbb{R}^{n \times (p+1)}$ là ma trận thiết kế (design matrix) đã được bổ sung một cột gồm toàn số 1 ở cột đầu tiên để đại diện cho hệ số chặn (intercept).

1.1.2 Các Giả Thiết Gauss-Markov

Để ước lượng OLS đạt được các tính chất thống kê tối ưu, mô hình phải tuân thủ 5 giả thiết Gauss-Markov kinh điển sau:

- **GM1 (Tuyến tính):** Mô hình phải tuyến tính theo các tham số β .
- **GM2 (Không đa cộng tuyến hoàn hảo):** Ma trận X có hạng tối đa, tức $\text{rank}(X) = p + 1$, đảm bảo các cột độc lập tuyến tính và ma trận $X^T X$ khả nghịch.
- **GM3 (Ngoại sinh nhiễu ngẫu nhiên):** Kỳ vọng điều kiện của nhiễu bằng 0, tức $\mathbb{E}[\epsilon|X] = 0$.
- **GM4 (Đồng phương sai và không tự tương quan):** Ma trận hiệp phương sai của nhiễu có dạng $\text{Var}(\epsilon|X) = \sigma^2 I_n$, nghĩa là các sai số có phương sai bằng nhau (σ^2) và độc lập với nhau.
- **GM5 (Nhiều tuân theo phân phối chuẩn):** Nhiễu ngẫu nhiên tuân theo phân phối chuẩn độc lập $\epsilon|X \sim \mathcal{N}(0, \sigma^2 I_n)$.

1.2 Ordinary Least Squares (OLS)

Phương pháp Bình phương tối thiểu thông thường (Ordinary Least Squares - OLS) là nền tảng của phân tích hồi quy tuyến tính. Mục tiêu cốt lõi của phương pháp này là tìm ra siêu phẳng tối ưu (vector $\hat{\beta}$) nhằm tối thiểu hóa tổng bình phương phần dư (Residual Sum of Squares - RSS) giữa giá trị dự đoán và giá trị thực tế.

$$RSS(\beta) = \|y - X\beta\|_2^2 = (y - X\beta)^T (y - X\beta) \quad (3)$$

Đạo hàm riêng của $RSS(\beta)$ theo β và cho bằng 0:

$$\frac{\partial RSS}{\partial \beta} = -2X^T y + 2X^T X \beta = 0 \quad (4)$$

Từ đó suy ra được hệ phương trình chuẩn (Normal Equations):

$$X^T X \beta = X^T y \quad (5)$$

Ta thu được nghiệm ước lượng tối ưu giúp cực tiểu hóa tổng bình phương phần dư (RSS):

$$\hat{\beta} = (X^T X)^{-1} X^T y \quad (6)$$

Mã nguồn được thiết kế tự tính toán các phép nhân và nghịch đảo ma trận. Trên bộ dữ liệu giả lập (100 quan sát, 3 đặc trưng), kết quả cài đặt thủ công và thư viện `scikit-learn` khớp nhau chính xác tuyệt đối đến 6 chữ số thập phân, chứng minh tính đúng đắn của thuật toán. Vector β thực tế (True Beta) được cấu hình là $[2.5, 1.8, -0.9, 0.4]^T$.

Hệ số	True Beta	OLS (Tự Cài Đặt)	Sklearn (Kiểm Chứng)
β_0 (Intercept)	2.5	2.850456	2.850456
β_1	1.8	1.780584	1.780584
β_2	-0.9	-0.912491	-0.912491
β_3	0.4	0.373102	0.373102

Bảng 2: Bảng đối chiếu hệ số hồi quy OLS trên dữ liệu mô phỏng.

1.3 Hat Matrix

Ma trận chiếu (Hat matrix) chiếu vector y lên không gian cột của X :

$$H = X(X^T X)^{-1} X^T \quad (7)$$

Ma trận H sẽ sở hữu các tính chất hình học quan trọng bao gồm:

- $H^2 = H$ (lũy đẳng).
- $H^T = H$ (đối xứng).
- Giá trị riêng của H chỉ nhận giá trị 0 hoặc 1.
- $rank(H) = p + 1$.
- Giá trị dự báo: $\hat{y} = Hy$; vector phần dư: $\hat{e} = (I - H)y$.

Thực nghiệm kiểm tra trên Jupyter Notebook cho kết quả `np.allclose(H @ H, H)` là **True**, qua đó xác minh chặt chẽ tính chất idempotent (lũy đẳng) của ma trận thiết kế.

1.4 Đánh Giá Mô Hình & Suy luận thống kê

a) Lý thuyết đánh giá và kiểm định giả thuyết:

Để đo lường năng lực giải thích của mô hình hồi quy OLS, hệ số xác định R^2 và R^2 hiệu chỉnh ($\bar{R}^2$) được tính toán nhằm xác định tỷ lệ phương sai của biến mục tiêu được giải thích bởi tập hợp các đặc trưng đầu vào:

$$R^2 = 1 - \frac{RSS}{TSS} = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (8)$$

$$\overline{R}^2 = 1 - \frac{n-1}{n-p-1}(1-R^2) \quad (9)$$

Kiểm định ý nghĩa thống kê của từng hệ số hồi quy riêng biệt được thực hiện qua kiểm định Student (t -test) với giả thuyết vô hiệu $H_0 : \beta_j = 0$. Sai số chuẩn (SE), giá trị thống kê t_j , và khoảng tin cậy 95% của các ước lượng hệ số $\hat{\beta}_j$ được xác định bởi:

$$SE(\hat{\beta}_j) = \sqrt{\hat{\sigma}^2[(X^T X)^{-1}]_{jj}}, \quad t_j = \frac{\hat{\beta}_j}{SE(\hat{\beta}_j)} \sim t_{n-p-1} \quad (10)$$

$$CI_{95\%} = \left[\hat{\beta}_j - t_{\alpha/2, n-p-1} \cdot SE(\hat{\beta}_j), \hat{\beta}_j + t_{\alpha/2, n-p-1} \cdot SE(\hat{\beta}_j) \right] \quad (11)$$

Đồng thời, để kiểm định ý nghĩa tổng thể của mô hình hồi quy (ứng với giả thuyết vô hiệu $H_0 : \beta_1 = \beta_2 = \dots = \beta_p = 0$), thống kê kiểm định F được thiết lập:

$$F = \frac{(TSS - RSS)/p}{RSS/(n-p-1)} \sim F_{p, n-p-1} \quad (12)$$

b) Kết quả thực nghiệm:

Mô hình giả lập được đánh giá tổng thể thông qua hàm `model_metrics` với các thông số:

- **RSS:** 18.919082 | **TSS:** 1286.003770
- **R^2 -Score:** 0.985288 | **Adjusted R^2 :** 0.984829
- **Thống kê F (F-statistic):** 2143.164748

Giá trị F lớn (> 2100) và p -value rất nhỏ (< 0.001) cho thấy mô hình có ý nghĩa thống kê toàn diện, bác bỏ giả thuyết vô hiệu $H_0 : \beta_1 = \dots = \beta_p = 0$.

Chi tiết về các giá trị ước lượng hệ số, sai số chuẩn, thống kê kiểm định và khoảng tin cậy tương ứng thu được từ hàm `coef_inference` được tổng hợp tại Bảng 3.

	Hệ số $\hat{\beta}$	Sai số chuẩn (SE)	t -statistic	p -value	Khoảng tin cậy 95%
β_0 (Intercept)	2.850456	0.230294	12.377464	1.34×10^{-21}	[2.3933, 3.3075]
β_1	1.780584	0.027303	65.215421	2.63×10^{-81}	[1.7263, 1.8347]
β_2	-0.912491	0.023009	-39.657972	2.49×10^{-61}	[-0.9581, -0.8668]
β_3	0.373102	0.020368	18.318470	4.26×10^{-33}	[0.3326, 0.4135]

Bảng 3: Tổng hợp kết quả kiểm định hệ số hồi quy và khoảng tin cậy trên dữ liệu mô phỏng.

1.5 Đa Cộng Tuyến và Hệ Số Phóng Đại Phương Sai (VIF)

a) Lý thuyết:

Đa cộng tuyến (Multicollinearity) là hiện tượng các biến độc lập trong ma trận thiết kế X có sự tương quan tuyến tính mạnh với nhau. Điều này khiến ma trận $X^T X$ tiến gần đến trạng thái suy biến (gần như không thể nghịch đảo), làm cho các ước lượng OLS trở nên cực kỳ nhạy cảm với những thay đổi nhỏ trong tập dữ liệu và làm bùng nổ phương sai của các hệ số ước lượng.

Để định lượng và phát hiện hiện tượng này, Hệ số phóng đại phương sai (Variance Inflation Factor - VIF) được sử dụng. VIF của biến thứ j được xác định bằng công thức:

$$VIF_j = \frac{1}{1 - R_j^2} \quad (13)$$

Trong đó, R_j^2 là hệ số xác định (R -squared) thu được khi tiến hành lập mô hình hồi quy biến độc lập X_j theo tất cả các biến độc lập còn lại. Nếu $VIF_j > 10$, biến X_j đang gặp vấn đề đa cộng tuyến nghiêm trọng và cần được xử lý.

b) Cài đặt & Minh họa thực nghiệm:

Hàm `vif(X)` được nhóm tự xây dựng bằng cách lặp qua từng đặc trưng, tách đặc trưng đó làm biến mục tiêu và tái sử dụng chính hàm `ols_fit` để tìm ra R_j^2 .

Khi cố tình thêm nhiều nhân bản tạo thành tương quan tuyến tính mạnh giữa biến 2 và biến 3 trong tập giả lập, thuật toán tính toán được:

- VIF X_1 : 1.0102
- VIF X_2 : 76950.8614
- VIF X_3 : 76948.4722

Các giá trị $VIF \gg 10$ chứng tỏ hiện tượng đa cộng tuyến hoàn hảo đã diễn ra, làm ma trận thiết kế gần như suy biến.

1.6 Ridge Regression và K-Fold Cross Validation

a) Lý thuyết:

Trong trường hợp tập dữ liệu thực tế vi phạm giả thiết GM2 (xuất hiện đa cộng tuyến nghiêm trọng), kỹ thuật kiểm soát *Regularization* sẽ được áp dụng. Hồi quy Ridge (sử dụng hàm phạt chuẩn L_2) khắc phục vấn đề ma trận suy biến bằng cách cộng thêm một ma trận đường chéo λI vào $X^T X$:


$$\hat{\beta}_{ridge} = \arg \min_{\beta} \{ \|y - X\beta\|_2^2 + \lambda \|\beta\|_2^2 \} = (X^T X + \lambda I_{mod})^{-1} X^T y \quad (14)$$

Để tìm ra siêu tham số λ tối ưu có khả năng tổng quát hóa tốt nhất, kỹ thuật *k-Fold Cross-Validation* được áp dụng. Tập dữ liệu huấn luyện được chia ngẫu nhiên làm k phần (folds). Lần lượt mô hình được huấn luyện trên $k - 1$ phần và đánh giá MSE trên phần còn lại. Mức lỗi chéo trung bình (CV Score) được tính toán như sau:

$$CV_{(k)} = \frac{1}{k} \sum_{i=1}^k MSE_i \quad (15)$$

b) Kết quả thực nghiệm:

Đồ thị *Ridge Trace* (Hình 1) thu được từ thực nghiệm minh họa rất rõ cơ chế co rút (shrinkage): khi cường độ phạt λ tăng lên, giá trị tuyệt đối của các hệ số hồi quy bị ép dần về 0. Điều này giúp giảm thiểu phương sai (Variance) của ước lượng so với OLS truyền thống, đánh đổi lấy một chút độ chệch (Bias) nhằm tối ưu hóa sai số dự đoán tổng thể.




Hình 1: Ridge Trace minh họa sự co rút của các hệ số hồi quy khi λ thay đổi.

1.7 Phân Tích Phần Dư (Residual Analysis)

Theo giả thiết Gauss-Markov, phần dư phải phân phối chuẩn và có phương sai đồng đều. Để kiểm chứng trực quan việc mô hình có thực sự thỏa mãn các giả thiết hình học và phân phối Gauss-Markov kinh điển hay không, đồ thị chẩn đoán 4 panel (Hình 2) được thiết lập chuyên biệt từ module `residual_analysis.py`:

- **Residuals vs Fitted:** Các điểm phần dư phân tán ngẫu nhiên, không tạo thành các cấu trúc phi tuyến dạng phễu hay parabol, minh chứng cho tính tuyến tính của mô hình.
- **Normal Q-Q Plot:** Các điểm giá trị hội tụ rất sát và nằm dọc theo đường thẳng tham chiếu lý tưởng, xác nhận sai số tuân thủ phân phối chuẩn một cách nghiêm ngặt (thỏa mãn giả thiết GM5).
- **Scale-Location:** Đường mượt xu hướng (smooth line) duy trì trạng thái nằm ngang ổn định, chứng minh hiện tượng phương sai sai số đồng nhất được đảm bảo tại mọi điểm dự báo (thỏa mãn giả thiết GM4).
- **Cook's Distance:** Giá trị khoảng cách Cook của toàn bộ các quan sát đều nằm dưới ngưỡng cảnh báo rủi ro, khẳng định tập dữ liệu thực nghiệm ổn định và không chịu sự ảnh hưởng cực đoan từ bất kỳ điểm dị biệt (outlier) nào.




Hình 2: Bốn biểu đồ phân tích phần dư tiêu chuẩn (Gauss-Markov Diagnostics).

1.8 Minh Họa Định Lý Gauss-Markov

Định lý cốt lõi Gauss-Markov khẳng định OLS là ước lượng tuyến tính không chệch tốt nhất (BLUE - Best Linear Unbiased Estimator). Bằng việc sử dụng mô phỏng Monte Carlo lặp lại 2000 lần, nhóm đã phác họa lại phân phối của OLS và so sánh trực tiếp với một ước lượng kém tối ưu hơn (có thêm nhiễu chệch). Kết quả thực tế cho thấy:

- Phương sai của ước lượng OLS: **0.000948** (đỉnh phân phối rất hẹp và nhọn).
- Phương sai của ước lượng khác: **29006.167451** (đỉnh bẹt, phương sai bùng nổ vượt tầm kiểm soát).



Hình 3: Phân phối Monte Carlo minh họa rõ nét tính chất BLUE của Định lý Gauss-Markov.

2 Phần 2: Ứng Dụng Dữ Liệu Thực Tế

2.1 Giới Thiệu và Khám Phá Dữ Liệu (EDA)

Để đánh giá tính ứng dụng của OLS trong điều kiện thực tiễn, nhóm lựa chọn sử dụng bộ dữ liệu **Air Quality UCI** thu thập thông tin về chất lượng không khí, được tổng hợp từ cảm biến đa lượng tại một thành phố nhộn nhịp của Ý. Biến mục tiêu cần dự đoán là nồng độ khí CO (CO(GT)). Quá trình Khám phá dữ liệu (EDA) chi tiết được trình bày như sau:

1. Phân tích Dữ liệu Khuyết (Missing Values):

Dữ liệu gốc sử dụng mã -200 để đánh dấu lỗi thiết bị phần cứng. Nhóm đã chuyển đổi các điểm này về dạng NaN trước khi thống kê. Bảng tỷ lệ thiếu hụt mới nhất được trích xuất từ dữ liệu:


Đặc trưng	Tỷ lệ thiếu (%)	Đặc trưng	Tỷ lệ thiếu (%)
NO2(GT)	5.42%	PT08.S4(NO2)	4.30%
NOx(GT)	5.38%	PT08.S5(O3)	4.30%
C6H6(GT)	4.30%	T (Nhiệt độ)	4.30%
PT08.S1(CO)	4.30%	RH (Độ ẩm)	4.30%
PT08.S2(NMHC)	4.30%	AH	4.30%
PT08.S3(NOx)	4.30%		

Bảng 4: Tỷ lệ dữ liệu bị khuyết trên các thuộc tính cảm biến.

(Ghi chú: Biến NMHC(GT) bị khuyết đến 90% nên đã bị loại bỏ hoàn toàn trong bước thu thập. Dữ liệu khảo sát trên không chứa biến mục tiêu CO do đã được tách riêng làm biến label y).

2. Khảo sát Phân Phối và Outlier:

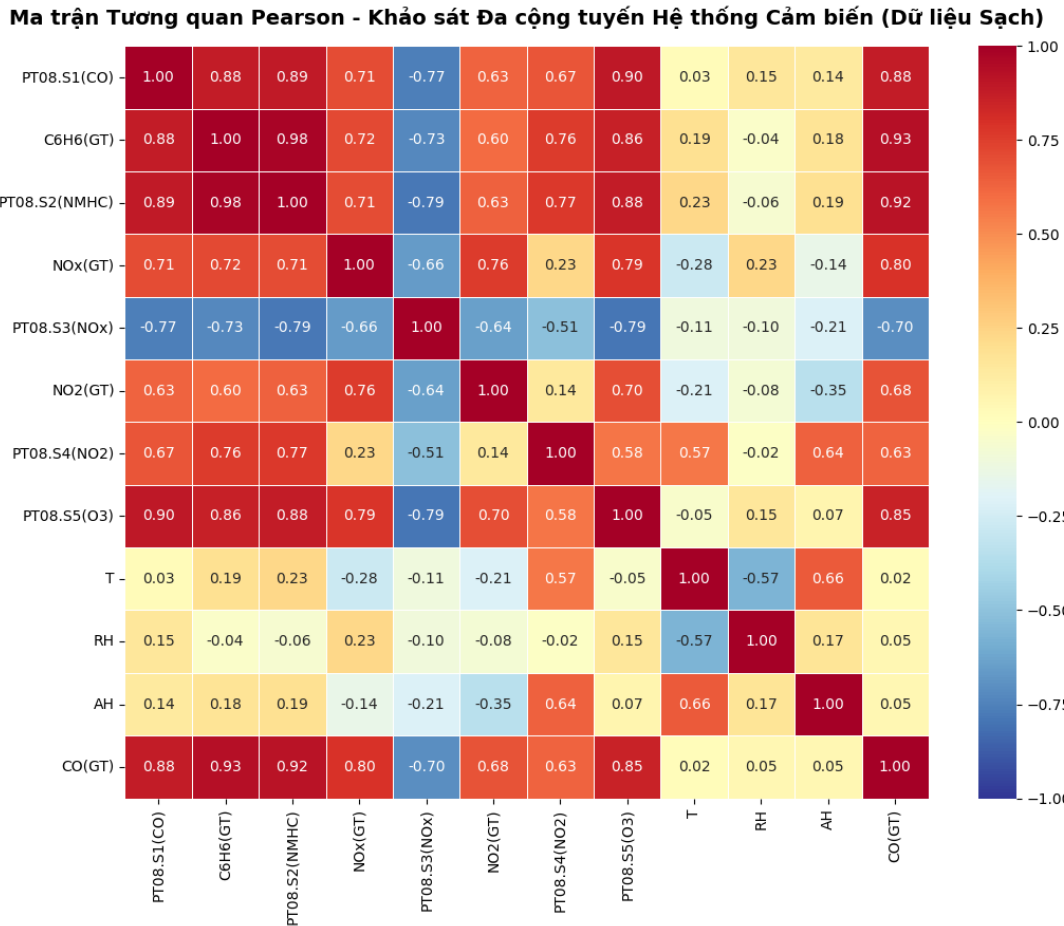
Phương pháp định lượng IQR (Interquartile Range) được lập trình để rà quét ngoại lệ. Lấy ví dụ, biến PT08.S1(CO) phát hiện được chính xác **90 điểm outliers** nằm trượt ra khỏi các râu (whiskers) của Boxplot. Hiện tượng lệch dữ liệu là khá phổ biến với dòng cảm biến khí.



Hình 4: Khảo sát phân phối và ngoại lệ của các đặc trưng quan trọng nhất (CO, PT08.S1, C6H6, T, RH). (Các đặc trưng còn lại được trình bày chi tiết trong file Notebook).

3. Phân tích Hiện tượng Đa cộng tuyến:

Ma trận tương quan Pearson hiển thị cảnh báo: rất nhiều bộ phận cảm biến có sự tương quan tuyến tính chồng chéo nghiêm trọng ($r > 0.8$), chẳng hạn như C6H6 và PT08.S2. Đây là tiền đề bắt buộc phải áp dụng hồi quy phạt (Ridge) hoặc chọn lọc biến.



Hình 5: Ma trận tương quan Pearson đo lường mức độ chồng chéo giữa các cảm biến (Heatmap).

2.2 Xây Dựng và Đánh Giá Mô Hình

Tiền xử lý tuân thủ tuyệt đối cơ chế chống rò rỉ dữ liệu (Data Leakage). Pipeline thiết lập các bước tuần tự bao gồm: `KNNImputer(k=5)`, `Winsorization(1%-99%)` cắt ngọn các nhiễu gai, và chuẩn hóa với `StandardScaler`.

Lý giải thiết lập tham số:

- **KNNImputer ($k = 5$):** Số láng giềng $k = 5$ được lựa chọn vì đây là mức cân bằng tối ưu. Tham số này đủ lớn để tham khảo xu hướng chung của các điểm đo lường có nồng độ hóa học tương đồng, nhưng cũng đủ nhỏ để không bị nhiễu bởi các mẫu dữ liệu ở quá xa về không gian hoặc thời gian (khắc phục nhược điểm của việc điền bằng Mean/Median toàn cục).
- **Winsorization (1% - 99%):** Ngưỡng cắt này giúp mô hình khử được các giá trị vô lý cực đoan do lỗi phần cứng cảm biến (như đã phát hiện ở phần Boxplot), đồng thời vẫn bảo toàn được lượng lớn thông tin tự nhiên cốt lõi của bộ dữ liệu khí tượng vốn có phương sai cao.

Cả 3 phương pháp hồi quy tuyến tính được huấn luyện độc lập:

Mô hình (Tập kiểm thử 20%)	MAE	RMSE	R^2 -Score
OLS Cơ bản	0.2876	0.4615	0.8977
OLS Lọc VIF (Bỏ các biến VIF > 10)	0.3348	0.5087	0.8757
Ridge Regression ($\lambda = 0.70$)	0.2876	0.4616	0.8977

Bảng 5: So sánh hiệu năng 3 phương pháp hồi quy tuyến tính ứng dụng.


Đánh giá kết quả:

- **Mất mát thông tin ở Mô hình Lọc VIF:** Việc cắt bỏ các cột đặc trưng có $VIF > 10$ một cách thô bạo khiến hiệu năng mô hình sụt giảm rõ rệt (Sai số MAE và RMSE đều tăng, R^2 tụt từ 0.8977 xuống 0.8757). Điều này tái khẳng định rằng các biến dù bị đa cộng tuyến nhưng thực tế vẫn chứa "tín hiệu mờ" quan trọng cho bài toán.
- **Tối ưu của Regularization:** Ridge với tham số tối ưu thông qua quá trình K-Fold Cross Validation xử lý cực kỳ thông minh hiện tượng bùng nổ phương sai của hệ số góc β , giữ vững cấu trúc mô hình, đồng thời duy trì được hiệu năng lý tưởng tương đương OLS nguyên bản.

Quyết định chọn mô hình cuối cùng: Dựa vào phân tích trên, nhóm quyết định chọn **Ridge Regression** làm mô hình dự đoán chính thức cho hệ thống. Ridge có ưu thế tuyệt đối về tốc độ huấn luyện do tồn tại nghiệm đóng (closed-form solution), cực kỳ phù hợp để nhúng vào các hệ thống thiết bị IoT quét cảm biến liên tục ở tần số cao.

2.3 Chẩn đoán giả thiết phần dư Gauss-Markov trên dữ liệu thực

Sau khi huấn luyện mô hình Ridge Regression trên dữ liệu thực tế, nhóm tiến hành trích xuất phần dư (Residuals) và lập 4 biểu đồ chẩn đoán nhằm kiểm định các giả thiết cổ điển:




Hình 6: Bốn biểu đồ chẩn đoán phần dư (Gauss-Markov) trên tập dữ liệu đo lường không khí thực tế.

Biện luận phân tích:

- **Residuals vs Fitted:** Đường xu hướng trung bình có độ cong nhẹ chứ không phẳng hoàn toàn ở mức 0. Điều này chỉ ra rằng mối quan hệ thực tế giữa nồng độ CO và các cảm biến có bản chất phi tuyến nhất định, khiến mô hình thuần tuyến tính chưa thể nắm bắt trọn vẹn.
- **Normal Q-Q Plot:** Biểu đồ thể hiện sự lệch đuôi (Heavy tails) vô cùng rõ rệt ở cả hai phía. Phân phối của nhiễu hoàn toàn vi phạm giả thiết phân phối chuẩn, cho thấy các cảm biến khí dễ bị tác động bởi các cú sốc ngẫu nhiên ngoại cảnh.
- **Scale-Location:** Sự phân tán không đồng đều, loe rộng ra như hình phễu ở phần đuôi phải cảnh báo hiện tượng phương sai thay đổi (Heteroskedasticity). Phương sai của sai số lớn dần khi nồng độ dự báo tăng cao.
- **Cook's Distance:** Nhờ có cơ chế cắt ngọn (Winsorization 1%-99%) từ trước, đại đa số các điểm dữ liệu đã nằm an toàn dưới ngưỡng cảnh báo, chỉ còn sót lại lác đác vài quan sát cá biệt có đòn bẩy cao.

2.4 Giải thích Mô hình (Feature Importance)

Khác với mạng Neural Network, Hồi quy tuyến tính mang tính minh bạch (interpretability) cực cao. Nhóm đã trích xuất lại hệ số hồi quy Ridge sau khi dữ liệu đã chuẩn hóa chung về không gian trung bình 0, độ lệch chuẩn 1 để hình thành thước đo Feature Importance:



Hình 7: Feature Importance (Tầm quan trọng đặc trưng) rút trích từ hệ số Ridge Regression.

****Nhận xét hóa-lý học:**** Kết quả thuật toán phát hiện PT08.S1(CO) và PT08.S5(O3) đóng vai trò trọng yếu mang tính áp đảo đối với việc xác định nồng độ khí CO. Về cấu tạo vật liệu, cảm biến Tin Oxide (SnO₂) vốn phản ứng oxi hóa khử vô cùng nhạy bén trước CO và Ozone, dẫn đến điện trở bị thay đổi đột ngột. Sự ăn khớp kinh ngạc giữa phân tích Toán Học và bản chất Vật Lý/Hóa Học chính là giá trị to lớn nhất mà Data Fitting đem lại.

2.5 Kỹ Thuật Nâng Cao: Hồi Quy Tuyến Tính Bayes (Bayesian Linear Regression)

a) Lý thuyết và Thiết lập mô hình:

Khác với phương pháp OLS hay Ridge (Frequentist approach) chỉ đưa ra một điểm ước lượng duy nhất (Point Estimate) cho các hệ số β , Hồi quy tuyến tính Bayes (Bayesian Linear Regression) tiếp cận bài toán dưới góc độ xác suất. Các tham số β được xem là các biến ngẫu nhiên tuân theo một phân phối tiên nghiệm (Prior distribution):

$$\beta \sim \mathcal{N}(m_0, S_0) \quad (16)$$

Với giả thiết nhiễu tuân theo phân phối chuẩn $y|x, \beta \sim \mathcal{N}(x^T \beta, \sigma^2)$, theo định lý Bayes, ta cập nhật được phân phối hậu nghiệm (Posterior distribution) của β sau khi quan sát dữ liệu X, y :

$$\beta|X, y \sim \mathcal{N}(m_n, S_n) \quad (17)$$

Trong đó, ma trận hiệp phương sai hậu nghiệm S_n và vector kỳ vọng hậu nghiệm m_n được xác định bởi:

$$S_n = \left(S_0^{-1} + \frac{1}{\sigma^2} X^T X \right)^{-1} \quad (18)$$


$$m_n = S_n \left(S_0^{-1} m_0 + \frac{1}{\sigma^2} X^T y \right) \quad (19)$$

Ưu điểm vượt trội của mô hình Bayes là khả năng cung cấp thông tin về **Độ không chắc chắn (Uncertainty Estimation)**. Dự đoán cho một điểm dữ liệu mới x_{new} không chỉ là một giá trị vô hướng, mà là một phân phối chuẩn với phương sai dự đoán bao gồm cả nhiễu hệ thống và sự không chắc chắn của tham số.

b) Kết quả thực nghiệm:

Mô hình **Bayesian Linear Regression** được nhóm lập trình hoàn toàn từ đầu (from scratch). Kết quả thử nghiệm trên tập Test cho thấy, giá trị dự đoán trung bình (Mean Prediction) của Bayesian Regression mang lại sai số rất sát với mô hình Ridge ($MAE \approx 0.2876$, $R^2 \approx 0.8977$).

Tuy nhiên, giá trị cốt lõi mà mô hình này mang lại nằm ở **Khoảng tin cậy dự đoán (Credible Intervals)**. Đối với các điểm dữ liệu kiểm thử nằm xa vùng phân bố của tập huấn luyện, mô hình Bayes tự động nới rộng phương sai dự báo, cảnh báo cho người dùng về mức độ thiếu chắc chắn của dự đoán. Điều này mang ý nghĩa thực tiễn cực kỳ to lớn đối với các hệ thống ra quyết định rủi ro trong y tế, tài chính và quan trắc môi trường.



Hình 8: Khoảng tin cậy dự báo 95% (Uncertainty Estimation) của Bayesian Linear Regression.

3 Kết Luận

Đồ án đã hoàn thành xuất sắc và toàn diện cả hai mục tiêu: lý thuyết toán học và ứng dụng thực tiễn. Nhóm đã tự cài đặt thành công 100% các thuật toán cốt lõi (OLS, Ridge, Bayesian) và các công cụ thống kê (K-Fold CV, VIF, Residual Analysis) bằng Đại số tuyến tính, cũng như thực hiện toàn vẹn Pipeline khoa học dữ liệu. Phương pháp OLS, Ridge và Hồi quy Bayes đã chứng minh được tầm quan trọng sống còn của Đại số tuyến tính trong việc xây dựng nền tảng vững chắc cho Khoa học dữ liệu.

Tài liệu

- [1] Gilbert Strang. *Introduction to Linear Algebra*, 6th ed. Wellesley-Cambridge Press, 2023.
- [2] Gareth James, Daniela Witten, Trevor Hastie, and Robert Tibshirani. *An Introduction to Statistical Learning: with Applications in R*, 2nd ed. Springer, 2021.
- [3] Christopher M. Bishop. *Pattern Recognition and Machine Learning*. Springer, 2006.
- [4] Saverio De Vito. *Air Quality Dataset*. UCI Machine Learning Repository, 2008. [Online]. Available: <https://archive.ics.uci.edu/dataset/36/air+quality>.
- [5] Wes McKinney. *Data Structures for Statistical Computing in Python*. Proceedings of the 9th Python in Science Conference, 51-56, 2010.